

**TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI
KHOA CÔNG NGHỆ THÔNG TIN**

-----o0o-----



BÁO CÁO BTL THỊ GIÁC MÁY TÍNH

ĐỀ TÀI:

**Phân tích, xây dựng và tối ưu hóa hệ thống học sâu nhận dạng
đối tượng trên ảnh Fisheye**

Giảng viên hướng dẫn :

TS. Vũ Huấn

Sinh viên thực hiện :

Chu Văn Dũng

Nhóm 10

MSV: 211210740

Trần Văn Đạt

Nhóm 10

MSV: 211214176

Đỗ Xuân Tùng

Nhóm 10

MSV: 211243774

Hà Nội, năm 2025

**TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI
KHOA CÔNG NGHỆ THÔNG TIN**

-----o0o-----



BÁO CÁO BTL THỊ GIÁC MÁY TÍNH

ĐỀ TÀI:

**Phân tích, xây dựng và tối ưu hóa hệ thống học sâu nhận dạng
đối tượng trên ảnh Fisheye**

Giảng viên hướng dẫn :

TS. Vũ Huấn

Sinh viên thực hiện :

Chu Văn Dũng

Nhóm 10

MSV: 211210740

Trần Văn Đạt

Nhóm 10

MSV: 211214176

Đỗ Xuân Tùng

Nhóm 10

MSV: 211243774

Hà Nội, năm 2025

LỜI MỞ ĐẦU

Với sự phát triển mạnh mẽ của Trí tuệ nhân tạo và Học máy, **Thị giác máy tính (Computer Vision)** ngày càng khẳng định vai trò then chốt trong các lĩnh vực như giao thông thông minh và giám sát an ninh. Một trong những bài toán tiêu biểu và thách thức nhất của thị giác máy tính là bài toán nhận dạng Đối tượng, nhưng việc xử lý dữ liệu thu thập từ camera mắt cá (Fisheye) đặt ra một thách thức lớn do biến dạng quang học nghiêm trọng, làm sai lệch hình dạng vật thể và giảm hiệu suất của mô hình học sâu.

Đề tài "**Phân tích, xây dựng và tối ưu hóa hệ thống học sâu Nhận dạng đối tượng trên ảnh Fisheye**" được thực hiện nhằm đề xuất giải pháp bằng việc tận dụng và so sánh các kiến trúc tiên tiến thuộc chuỗi YOLO (bao gồm YOLOv8 và phiên bản mới nhất YOLOv11). Điểm nhấn của nghiên cứu là việc triển khai kỹ thuật Tổ hợp mô hình (Ensemble) sử dụng Weighted Boxes Fusion (WBF), nhằm kết hợp ưu điểm của các mô hình đã huấn luyện để đạt được chỉ số mAP và F1-score tối ưu trong môi trường ảnh Fisheye biến dạng.

Nội dung báo cáo được trình bày trong 05 chương chính nhằm cung cấp cái nhìn toàn diện từ cơ sở lý thuyết đến kết quả thực nghiệm:

- **Chương 1:** Tổng quan về bài toán Nhận dạng đối tượng trên ảnh Fisheye và cơ sở lý thuyết.
- **Chương 2:** Phân tích kiến trúc mô hình học sâu YOLOv8 và YOLOv11.
- **Chương 3:** Thiết lập huấn luyện và tăng cường dữ liệu.
- **Chương 4:** Kỹ thuật tổ hợp mô hình với Weighted Boxes Fusion.
- **Chương 5:** Đánh giá kết quả và thảo luận.

Chúng em xin gửi lời cảm ơn chân thành đến thầy Vũ Huân đã tận tình hướng dẫn và định hướng nghiên cứu trong suốt quá trình thực hiện đề tài. Dù đã triển khai được một hệ thống nhận diện đối tượng hiệu suất cao, do hạn chế về thời gian, kiến thức và kinh nghiệm, báo cáo không thể tránh khỏi những thiếu sót. Chúng em rất mong nhận được sự đóng góp, nhận xét của thầy để bài báo cáo được hoàn thiện hơn.

MỤC LỤC

LỜI MỞ ĐẦU	1
MỤC LỤC.....	2
DANH MỤC BẢNG.....	5
CHƯƠNG 1: TỔNG QUAN VỀ BÀI TOÁN NHẬN DẠNG ĐỐI TƯỢNG TRÊN ẢNH FISHEYE	6
1.1 Giới thiệu chung về Thị giác máy tính.....	6
1.1.1 Khái niệm và vai trò của Thị giác máy tính.....	6
1.1.2 Quá trình phát triển của Thị giác máy tính	6
1.1.3 Học sâu (Deep Learning) trong Thị giác máy tính.....	7
1.1.4 Các hướng tiếp cận chính trong Thị giác máy tính hiện đại.....	7
1.1.5 Xu hướng ứng dụng trong bối cảnh mới – ảnh Fisheye và camera phi tuyến tính.....	8
1.2 Giới thiệu Học sâu và ứng dụng trong Thị giác máy tính	8
1.2.1 Khái quát về Học sâu trong Thị giác máy tính	8
1.2.2 Mạng tích chập (CNN) – Nền tảng của Học sâu trong CV	8
1.2.3 Ưu điểm của học sâu so với phương pháp truyền thống	9
1.2.4 Liên hệ với mô hình YOLO.....	9
1.3 Tổng quan về YOLO.....	9
1.3.1 Lịch sử phát triển của YOLO	9
1.3.2 Nguyên lý cơ bản YOLO	10
1.3.3 So sánh YOLO với R-CNN và SSD	10
CHƯƠNG 2: PHÂN TÍCH KIẾN TRÚC MÔ HÌNH HỌC SÂU YOLOv8 VÀ YOLOv11	11
2.1. Tổng quát về YOLO	11
2.1.1. Kiến trúc tổng thể của YOLO.....	11
2.1.2. Ưu điểm của kiến trúc YOLO.....	11
2.1.3. So sánh tổng quan với các mô hình khác.....	11
2.2. Kiến trúc YOLOv8.....	12
2.2.1. Giới thiệu chung.....	12

2.2.2. Cấu trúc chi tiết.....	13
2.2.3. Các kỹ thuật huấn luyện và tối ưu	14
2.2.4. Hiệu năng và ứng dụng thực tế.....	14
2.2.5. Ý nghĩa đối với bài toán ảnh Fisheye	15
2.3. Kiến trúc YOLOv11.....	15
2.3.1. Giới thiệu chung.....	15
2.3.2. Cấu trúc chi tiết.....	16
2.3.3. Các kỹ thuật huấn luyện và tối ưu	17
2.3.4. Hiệu năng và ứng dụng thực tế.....	17
2.3.5. Ý nghĩa đối với bài toán ảnh Fisheye	18
CHƯƠNG 3: THIẾT LẬP HUẤN LUYỆN VÀ TĂNG CƯỜNG DỮ LIỆU ...	19
3.1. Chuẩn bị dữ liệu.....	19
3.1.1 Nguồn dữ liệu.....	19
3.2.2. Tiền xử lý và chia dữ liệu	19
3.2. Thử nghiệm ban đầu và lựa chọn mô hình chính.....	20
3.2.1. Mục tiêu thử nghiệm.....	20
3.2.2. Kết quả so sánh	20
3.2.3. Phân tích kết quả.....	20
3.2.4. Kết luận lựa chọn.....	21
3.3. Huấn luyện mở rộng với YOLOv11	21
3.4. Gán nhãn giả và tinh chỉnh mô hình	21
3.4.1. Mục tiêu	21
3.4.2. Quy trình thực hiện	21
3.4.3. Kết quả tinh chỉnh.....	22
3.5. Tổ hợp mô hình bằng Weighted Boxes Fusion (WBF).....	22
3.5.1. Mục tiêu	22
3.5.2. Quy trình tổ hợp.....	22
3.5.3. Kết quả tổ hợp.....	23
CHƯƠNG 4: KỸ THUẬT TỔ HỢP MÔ HÌNH VỚI WEIGHTED BOXES FUSION.....	24

4.1. Mục tiêu đánh giá.....	24
4.2. Kết quả huấn luyện và so sánh.....	24
4.3. Phân tích định tính	25
4.4. Thảo luận kết quả.....	25
CHƯƠNG 5: ĐÁNH GIÁ KẾT QUẢ VÀ THẢO LUẬN	26
5.1. Kết luận chung	26
5.2. Hạn chế của nghiên cứu	26
5.3. Hướng phát triển tương lai.....	27
5.4. Kết luận cuối cùng	27
Tài Liệu Tham Khảo	28

DANH MỤC BẢNG

BẢNG 1.1	BẢNG SO SÁNH HỌC SÂU VÀ PHƯƠNG PHÁP TRUYỀN THỐNG	9
BẢNG 1.2	BẢNG SO SÁNH YOLO VỚI R-CNN VÀ SSD.....	10
BẢNG 2.1	BẢNG CẤU TRÚC TỔNG THỂ CỦA YOLO	11
BẢNG 2.2	BẢNG SO SÁNH YOLO VỚI R-CNN VÀ SSD.....	12
BẢNG 2.3	BẢNG CẢI TIẾN YOLOV11	17
BẢNG 2.4	BẢNG SO SÁNH YOLOV8M VÀ YOLOV11M.....	17
BẢNG 3.1	BẢNG CÁC BỘ DỮ LIỆU.....	19
BẢNG 4.1	BẢNG KẾT QUẢ HUẤN LUYỆN VÀ SO SÁNH	24

CHƯƠNG 1: TỔNG QUAN VỀ BÀI TOÁN NHẬN DẠNG ĐỐI TƯỢNG TRÊN ẢNH FISHEYE

1.1 Giới thiệu chung về Thị giác máy tính

1.1.1 Khái niệm và vai trò của Thị giác máy tính

Thị giác máy tính (*Computer Vision*) là một lĩnh vực thuộc trí tuệ nhân tạo (Artificial Intelligence), tập trung vào việc giúp máy tính hiểu và diễn giải thông tin hình ảnh hoặc video tương tự như khả năng thị giác của con người. Mục tiêu của thị giác máy tính là cho phép hệ thống tự động nhận biết, phân loại và định vị các đối tượng, từ đó hỗ trợ ra quyết định hoặc hành động trong môi trường thực tế.

Trong những năm gần đây, thị giác máy tính đã trở thành trụ cột quan trọng của các hệ thống thông minh hiện đại, xuất hiện trong nhiều ứng dụng thực tế như:

- **Xe tự hành (Autonomous Driving):** nhận diện người đi bộ, phương tiện, đèn giao thông.
- **Giám sát an ninh (Surveillance):** phát hiện xâm nhập, theo dõi hành vi bất thường.
- **Y học (Medical Imaging):** phát hiện khối u, phân tích ảnh X-quang hoặc MRI.
- **Công nghiệp thông minh (Smart Manufacturing):** kiểm tra lỗi sản phẩm, robot thị giác.
- **Thực tế tăng cường (Augmented Reality):** theo dõi chuyển động, định vị vật thể trong không gian 3D.

Nhờ sự phát triển mạnh mẽ của phần cứng tính toán (GPU, TPU) và thuật toán học sâu, các hệ thống thị giác máy tính hiện nay có thể đạt độ chính xác tương đương, thậm chí vượt con người trong một số tác vụ đặc thù như nhận diện khuôn mặt, phân loại hình ảnh hay phát hiện đối tượng.

1.1.2 Quá trình phát triển của Thị giác máy tính

Giai đoạn đầu (trước năm 2012), các hệ thống CV chủ yếu dựa vào phương pháp trích xuất đặc trưng thủ công (hand-crafted features) như:

- **SIFT** (Scale-Invariant Feature Transform),
- **HOG** (Histogram of Oriented Gradients),
- **SURF** (Speeded-Up Robust Features),
- **LBP** (Local Binary Pattern).

Những đặc trưng này sau đó được đưa vào các bộ phân loại như SVM (Support Vector Machine) hoặc Random Forest để dự đoán nhãn ảnh.

Tuy nhiên, các phương pháp này bị giới hạn bởi khả năng biểu diễn đặc trưng thấp và không thích ứng tốt với dữ liệu phức tạp hoặc biến dạng hình học.

Bước ngoặt lớn đến từ mạng nơ-ron tích chập (Convolutional Neural Network – CNN), mở đầu với LeNet-5 (Yann LeCun, 1998), và đặc biệt là AlexNet (Krizhevsky et al., 2012) – mô hình đã chiến thắng cuộc thi ImageNet Large Scale Visual Recognition Challenge (ILSVRC) năm 2012 với độ chính xác vượt trội so với mọi phương pháp truyền thống. Kể từ đó, học sâu (*Deep Learning*) trở thành phương pháp chủ đạo trong Thị giác máy tính.

1.1.3 Học sâu (Deep Learning) trong Thị giác máy tính

Học sâu là một nhánh của học máy (Machine Learning) sử dụng mạng nơ-ron nhân tạo nhiều tầng (Deep Neural Networks) để học các đặc trưng trực tiếp từ dữ liệu đầu vào mà không cần thiết kế thủ công.

Cấu trúc cơ bản của một mạng học sâu bao gồm:

- **Tầng đầu vào (Input Layer):** nhận dữ liệu hình ảnh thô (pixel).
- **Các tầng ẩn (Hidden Layers):** thực hiện phép tích chập (convolution), phi tuyến (activation) và gộp (pooling) để trích xuất đặc trưng ở nhiều mức độ trừu tượng.
- **Tầng đầu ra (Output Layer):** thực hiện dự đoán (phân loại, định vị đối tượng, v.v.).

Trong lĩnh vực phát hiện đối tượng (*Object Detection*), học sâu mang lại những lợi thế vượt trội:

- Tự động học đặc trưng không gian–ngữ nghĩa phức tạp từ ảnh.
- Khả năng mở rộng cho nhiều loại dữ liệu khác nhau (ảnh RGB, ảnh fisheye, ảnh nhiệt...).
- Tốc độ xử lý cao khi kết hợp với GPU, phù hợp cho ứng dụng thời gian thực.

1.1.4 Các hướng tiếp cận chính trong Thị giác máy tính hiện đại

Hiện nay, hầu hết các bài toán trong CV đều dựa vào các kiến trúc mạng học sâu, trong đó nổi bật là:

- **Phân loại ảnh (Image Classification):** ResNet, EfficientNet, ConvNeXt.
- **Phát hiện đối tượng (Object Detection):** YOLO, Faster R-CNN, RetinaNet.

- **Phân đoạn ảnh (Segmentation):** U-Net, Mask R-CNN, Segment Anything Model (SAM).
- **Nhận diện tư thế (Pose Estimation):** OpenPose, HRNet.

Trong đó, phát hiện đối tượng (Object Detection) – nhiệm vụ xác định loại đối tượng và vị trí (bounding box) của nó trong ảnh – là trọng tâm của đề tài này. Với yêu cầu vừa nhanh, vừa chính xác, các mô hình dòng YOLO (You Only Look Once) đã trở thành chuẩn mực cho bài toán phát hiện thời gian thực.

1.1.5 Xu hướng ứng dụng trong bối cảnh mới – ảnh Fisheye và camera phi tuyến tính

Trong các hệ thống giám sát hiện đại, camera fisheye được sử dụng rộng rãi nhờ khả năng bao quát góc nhìn lên đến 180–360°, giúp giảm số lượng camera cần thiết. Tuy nhiên, sự xuất hiện của biến dạng phi tuyến (non-linear distortion) khiến các mô hình CV thông thường khó đạt hiệu quả cao.

Điều này đặt ra nhu cầu nghiên cứu các kiến trúc học sâu tối ưu cho dữ liệu fisheye, kết hợp với các kỹ thuật huấn luyện và tổ hợp mô hình tiên tiến để cải thiện độ chính xác – chính là hướng mà bài báo cáo này tập trung khai thác.

1.2 Giới thiệu Học sâu và ứng dụng trong Thị giác máy tính

1.2.1 Khái quát về Học sâu trong Thị giác máy tính

Học sâu (Deep Learning) là một nhánh của Học máy (Machine Learning) sử dụng các mạng nơ-ron nhiều tầng (Deep Neural Networks) để tự động học đặc trưng từ dữ liệu thô.

Trong lĩnh vực Thị giác máy tính, học sâu đã mang lại bước tiến vượt bậc trong các bài toán như: phân loại ảnh, phát hiện đối tượng, phân đoạn ngữ nghĩa, nhận dạng khuôn mặt, và ước lượng tư thế.

Khác với các phương pháp truyền thống phải thiết kế đặc trưng thủ công (SIFT, HOG), học sâu có khả năng tự học biểu diễn đặc trưng từ dữ liệu, giúp mô hình thích nghi tốt hơn với dữ liệu phức tạp và biến đổi thực tế.

1.2.2 Mạng tích chập (CNN) – Nền tảng của Học sâu trong CV

Mạng CNN (Convolutional Neural Network) là kiến trúc phổ biến nhất trong thị giác máy tính. Một mạng CNN điển hình gồm:

- **Tầng tích chập (Convolution):** trích xuất đặc trưng cục bộ từ ảnh.

- **Tầng gộp (Pooling):** giảm kích thước không gian và tăng tính bất biến vị trí.
- **Hàm kích hoạt (ReLU, LeakyReLU):** tạo phi tuyến cho phép mô hình học đặc trưng phức tạp.
- **Batch Normalization và Skip Connection:** giúp mô hình hội tụ nhanh và ổn định hơn.

Nhờ cơ chế chia sẻ trọng số và học đặc trưng đa tầng, CNN vừa giảm số tham số cần học vừa đạt hiệu năng cao hơn nhiều so với các phương pháp truyền thống.

1.2.3 Ưu điểm của học sâu so với phương pháp truyền thống

Đặc điểm	Phương pháp truyền thống	Học sâu (CNN)
Thiết kế đặc trưng	Cần thủ công (SIFT, HOG)	Tự động học từ dữ liệu
Biểu diễn	Đơn giản, khó mở rộng	Mạnh mẽ, nhiều tầng trừu tượng
Hiệu năng	Phụ thuộc đặc trưng thủ công	Hiệu năng cao, tổng quát tốt
Ứng dụng thực tế	Giới hạn	Ứng dụng rộng (xe tự hành, y tế, robot, giám sát, v.v.)

Bảng 1.1 Bảng so sánh Học sâu và Phương pháp truyền thống

1.2.4 Liên hệ với mô hình YOLO

YOLO là ví dụ điển hình của việc ứng dụng mạng CNN trong phát hiện đối tượng thời gian thực (real-time). YOLO sử dụng CNN làm Backbone để trích xuất đặc trưng, sau đó qua Neck và Head để dự đoán vị trí (bounding box) và loại đối tượng.

Nhờ khai thác tối đa sức mạnh của học sâu, YOLO đạt được sự cân bằng giữa tốc độ và độ chính xác, trở thành một trong những mô hình phổ biến nhất trong các ứng dụng thực tế của thị giác máy tính.

1.3 Tổng quan về YOLO

1.3.1 Lịch sử phát triển của YOLO

YOLO (You Only Look Once) là một trong những kiến trúc phát hiện đối tượng (Object Detection) nổi bật nhất hiện nay. Được giới thiệu lần đầu bởi Joseph Redmon vào năm 2016, YOLO đã nhanh chóng trở thành nền tảng cho các hệ thống nhận dạng thời gian thực nhờ tốc độ vượt trội và độ chính xác cao.

Quá trình phát triển của YOLO trải qua nhiều thế hệ, với các cải tiến liên tục về cấu trúc mạng, tốc độ xử lý và khả năng tổng quát hóa.

1.3.2 Nguyên lý cơ bản YOLO

Khác với các mô hình phát hiện truyền thống (như R-CNN), YOLO xem bài toán phát hiện đối tượng như một bài toán hồi quy duy nhất (single regression problem). Cụ thể:

- Mô hình chia ảnh đầu vào thành lưới (grid cells).
- Mỗi ô lưới dự đoán vị trí bounding box, độ tin cậy (confidence), và nhãn lớp của đối tượng.
- Tất cả các dự đoán được tính toán chỉ trong một lần quét ảnh (single forward pass) qua mạng CNN.

Nhờ cơ chế này, YOLO đạt được tốc độ xử lý vượt trội (real-time) mà vẫn đảm bảo độ chính xác cao. Nguyên lý “You Only Look Once” thể hiện triết lý cốt lõi: một mô hình duy nhất, một lần nhìn, dự đoán toàn bộ đối tượng trong ảnh.

1.3.3 So sánh YOLO với R-CNN và SSD

Tiêu chí	R-CNN / Fast R-CNN / Faster R-CNN	SSD (Single Shot Detector)	YOLO
Cách phát hiện	Hai giai đoạn: trích xuất vùng đề xuất → phân loại	Một giai đoạn, dự đoán đa tỉ lệ	Một giai đoạn, xử lý toàn ảnh trong một lần
Tốc độ	Chậm (khoảng 5–10 FPS)	Trung bình (20–30 FPS)	Rất nhanh (≥ 60 FPS, real-time)
Độ chính xác	Cao trên đối tượng nhỏ	Tốt, nhưng vẫn hạn chế ở kích thước nhỏ	Cân bằng tốt giữa tốc độ và độ chính xác
Tính triển khai	Cồng kềnh, khó dùng cho real-time	Tốt hơn R-CNN	Dễ triển khai trên GPU, Edge AI, mobile
Ứng dụng	Học thuật, nghiên cứu	Ứng dụng thực tế, robot, xe tự hành	Real-time detection, giám sát, drone, công nghiệp

Bảng 1.2 Bảng so sánh Yolo với R-CNN và SSD

Nhờ thiết kế đơn giản, tốc độ nhanh và khả năng tổng quát cao, YOLO đã trở thành lựa chọn phổ biến trong các ứng dụng cần nhận dạng thời gian thực như camera giám sát, xe tự hành, drone, hay hệ thống giao thông thông minh.

CHƯƠNG 2: PHÂN TÍCH KIẾN TRÚC MÔ HÌNH HỌC SÂU YOLOv8 VÀ YOLOv11

2.1. Tổng quát về YOLO

2.1.1. Kiến trúc tổng thể của YOLO

Cấu trúc tổng thể của họ YOLO gồm **ba phần chính**:

Thành phần	Vai trò	Đặc điểm
Backbone	Trích xuất đặc trưng (features) từ ảnh đầu vào.	Các phiên bản YOLO mới dùng CSPNet, C2f, C3k2 để tăng khả năng tái sử dụng đặc trưng và giảm tham số.
Neck	Kết hợp đặc trưng đa tầng (multi-scale).	Dựa trên FPN + PANet, và được cải tiến trong YOLOv8/v11 để giảm trễ tính toán.
Head	Dự đoán hộp (bounding box), nhãn (class) và độ tin cậy (confidence).	YOLOv8 trở đi dùng anchor-free detection, giúp đơn giản hóa huấn luyện và tăng độ linh hoạt.

Bảng 2.1 Bảng cấu trúc tổng thể của Yolo

2.1.2. Ưu điểm của kiến trúc YOLO

- **Tốc độ cao:** YOLO xử lý ảnh theo cơ chế end-to-end, rất phù hợp cho các ứng dụng thời gian thực như xe tự hành hoặc giám sát thông minh.
- **Hiệu suất tốt:** YOLO đạt độ chính xác cao (mAP lớn) trong khi vẫn đảm bảo tốc độ suy luận (inference) nhanh.
- **Dễ triển khai:** Các phiên bản mới (v5–v11) được phát triển bằng PyTorch, dễ dàng huấn luyện, tinh chỉnh (fine-tuning) và triển khai trên GPU hoặc thiết bị Edge.

2.1.3. So sánh tổng quan với các mô hình khác

Tiêu chí	R-CNN	SSD	YOLO
Số giai đoạn xử lý	2 (Region proposal + classification)	1	1
Tốc độ	Chậm	Nhanh	Rất nhanh

Độ chính xác	Cao	Trung bình	Cao
Khả năng triển khai real-time	Không	Có	Rất tốt

Bảng 2.2 Bảng so sánh yolo với R-CNN và SSD

2.2. Kiến trúc YOLOv8


2.2.1. Giới thiệu chung

YOLOv8 (Ultralytics, 2023) là phiên bản đầu tiên anchor-free, được thiết kế tối ưu cho tốc độ và độ chính xác.

Ba điểm nổi bật:

- Cải tiến CSPNet backbone → tăng tái sử dụng đặc trưng.
- FPN + PAN Neck tối ưu truyền thông tin đa cấp.
- Loại bỏ anchor → đơn giản hơn và tổng quát hơn cho các loại ảnh phi tuyến như fisheye.

2.2.2. Cấu trúc chi tiết



YOLOv8 tuân theo cấu trúc 3 phần chính: Backbone → Neck → Head, trong đó từng phần có cải tiến rõ rệt.

1. Backbone – Trích xuất đặc trưng

- Thành phần chính là C2f block, một biến thể cải tiến từ CSP (Cross Stage Partial Network) của YOLOv5.
- Mỗi C2f block kết hợp nhiều tầng convolution với cơ chế shortcut connections, giúp truyền thông tin giữa các lớp sâu mà không bị mất đặc trưng.
- Ưu điểm:

- Giảm số lượng tham số (parameters) nhưng vẫn duy trì độ chính xác cao.
- Cải thiện khả năng hội tụ và tránh hiện tượng “gradient vanishing”.

2. Neck – Tổng hợp đặc trưng đa cấp

- YOLOv8 sử dụng SPPF (Spatial Pyramid Pooling – Fast) để trích xuất đặc trưng ở nhiều thang độ.
- Cơ chế này giúp mô hình xử lý các đối tượng có kích thước khác nhau (nhỏ, trung bình, lớn) hiệu quả hơn.
- Neck kết hợp đặc trưng từ nhiều tầng Backbone qua FPN + PAN (Feature Pyramid Network + Path Aggregation Network), đảm bảo thông tin không gian và ngữ nghĩa được giữ nguyên.

3. Head – Phát hiện đối tượng (Anchor-free Head)

- YOLOv8 loại bỏ hoàn toàn cơ chế anchor boxes truyền thống, thay bằng anchor-free detection head.
- Head của mô hình gồm hai nhánh song song:
 - **Nhánh phân loại (Classification)** – dự đoán lớp đối tượng.
 - **Nhánh định vị (Localization)** – dự đoán trực tiếp tọa độ (x, y, w, h) của hộp giới hạn.
- Cơ chế anchor-free giúp:
 - Giảm khối lượng tính toán.
 - Tăng tốc độ huấn luyện.
 - Dễ dàng mở rộng sang các loại dữ liệu khác nhau (ví dụ ảnh Fisheye có hình dạng méo).

2.2.3. Các kỹ thuật huấn luyện và tối ưu

- **Mosaic + Mixup Augmentation** → tạo ảnh tổ hợp từ nhiều ảnh gốc, giúp mô hình tổng quát hơn.
- **Focal Loss + IoU Loss + Objectness Loss** → cân bằng giữa phân loại và định vị.
- **Mixed Precision Training (FP16)** → tăng tốc huấn luyện mà không giảm chính xác.
- **Tối ưu cho Edge AI**: hỗ trợ xuất sang ONNX, TensorRT, và chạy tốt trên GPU lẫn CPU.

2.2.4. Hiệu năng và ứng dụng thực tế

- **Tốc độ**: YOLOv8 có thể đạt trên 300 FPS khi chạy trên GPU RTX 3090 (với input 640×640).

- **Độ chính xác**: mAP (Mean Average Precision) cao hơn 1–2% so với YOLOv5 cùng kích thước mô hình.

- **Tính linh hoạt:** Hỗ trợ nhiều kích cỡ mô hình (n, s, m, l, x) phù hợp với yêu cầu tài nguyên.

- **Ứng dụng:** YOLOv8 được dùng rộng rãi trong các lĩnh vực như giám sát giao thông, phát hiện người trong khu vực nguy hiểm, nhận dạng phương tiện hoặc hàng hóa trong kho.

2.2.5. Ý nghĩa đối với bài toán ảnh Fisheye

Nhờ anchor-free và cơ chế trích xuất đa thang, YOLOv8 thích hợp cho ảnh Fisheye — nơi hình dạng vật thể bị méo và lệch góc nhìn. Cấu trúc C2f + SPPF + FPN/PAN giúp giữ vững thông tin không gian và phát hiện vật thể nhỏ ở rìa ảnh.

2.3. Kiến trúc YOLOv11

2.3.1. Giới thiệu chung


YOLOv11 là phiên bản mới nhất của dòng YOLO, được công bố vào cuối năm 2024 bởi Ultralytics, kế thừa trực tiếp từ YOLOv8. Mục tiêu thiết kế của YOLOv11 là tăng hiệu quả tính toán và nâng cao độ chính xác, trong khi vẫn duy trì khả năng suy luận thời gian thực (real-time inference).

Các cải tiến chính gồm:

- Giới thiệu khối C3k2 trong Backbone, thay thế C2f của YOLOv8, giúp giảm số tham số mà vẫn giữ hiệu năng.
- Tích hợp C2PSA (Convolutional block with Parallel Spatial Attention), giúp mô hình tập trung vào vùng ảnh quan trọng hơn.
- Hỗ trợ đa nhiệm (multi-task): phát hiện, phân đoạn, nhận dạng tư thế (pose) và hộp quay (oriented bounding box – OBB).

YOLOv11 được xem là phiên bản cân bằng tốt nhất giữa tốc độ, độ chính xác và khả năng triển khai trên thiết bị giới hạn tài nguyên (Edge AI).

2.3.2. Cấu trúc chi tiết



YOLOv11 vẫn giữ nguyên triết lý thiết kế **Backbone – Neck – Head**, nhưng từng phần được tối ưu lại đáng kể.

Thành phần	Cấu trúc / Cải tiến	Vai trò và lợi ích
Backbone	Sử dụng C3k2 block , thay cho C2f. Mỗi C3k2 gồm hai tầng tích chập kernel=2 thay vì một conv lớn.	Giảm ~22% tham số, tăng tốc độ xử lý và tiết kiệm bộ nhớ.
Neck	Giữ nguyên FPN + PAN nhưng thay block hợp nhất đặc trưng bằng C3k2.	Tăng hiệu quả truyền đặc trưng giữa các tầng, tối ưu phát hiện đa kích thước.
SPPF + C2PSA	Giữ lại Spatial Pyramid Pooling – Fast , đồng thời chèn	Cải thiện khả năng tập trung không gian, giúp mô hình

	thêm khối Parallel Spatial Attention (PSA) sau đó.	nhận diện tốt vật thể nhỏ hoặc che khuất.
Head (Anchor-free)	Dự đoán trực tiếp bounding box và confidence mà không cần anchor.	Giữ tốc độ cao, giảm lỗi anchor mismatch, phù hợp với dữ liệu méo (fisheye).

Bảng 2.3 Bảng cải tiến Yolov11

2.3.3. Các kỹ thuật huấn luyện và tối ưu

YOLOv11 sử dụng chiến lược huấn luyện tương tự YOLOv8 nhưng được tinh chỉnh cho hiệu năng cao hơn:

- **Optimizer:** AdamW với learning rate động (cosine annealing scheduler).
- **Loss Function:** Kết hợp **Distribution Focal Loss**, **CIoU Loss**, và **Objectness Loss** để cân bằng giữa phân loại và định vị.
- **Data Augmentation:** Giữ Mosaic và Mixup, đồng thời thêm random scaling và color jitter để mô hình bền vững hơn.
- **Mixed Precision (FP16)** và **Batch Normalization cải tiến (GroupNorm)** giúp tăng tốc độ huấn luyện.
- **Fine-tuning hỗ trợ transfer learning:** dễ dàng tái huấn luyện trên dataset nhỏ (ví dụ Fisheye8k).

Các kỹ thuật này giúp YOLOv11 đạt hiệu suất huấn luyện cao hơn, giảm thời gian hội tụ và tối ưu sử dụng bộ nhớ GPU.

2.3.4. Hiệu năng và ứng dụng thực tế

Kết quả đánh giá trên bộ COCO dataset cho thấy YOLOv11 có những cải thiện đáng kể so với YOLOv8.

Phiên bản	mAP@0.5	Latency (ms)	Tham số (M)	Cải tiến chính
YOLOv8m	51.0	8.0	25.0	Anchor-free, C2f
YOLOv11m	54.5	6.5	19.5	C3k2 + C2PSA Attention

Bảng 2.4 Bảng so sánh Yolov8m và Yolov11m

- Hiệu quả tính toán: giảm ~22% tham số nhưng tăng tốc độ suy luận ~20%.
- Độ chính xác: tăng ~3.5% mAP so với YOLOv8m.

- Khả năng mở rộng: hỗ trợ xuất ONNX, TensorRT, CoreML — dễ triển khai trên Edge AI.

Ứng dụng thực tế:

- Nhận dạng người và phương tiện trong giám sát an ninh (fisheye camera).
- Phát hiện vật cản trong xe tự hành.
- Kiểm tra chất lượng sản phẩm trong sản xuất thông minh.
- Phân đoạn và nhận dạng đối tượng trong ảnh góc rộng hoặc camera 360°.

2.3.5. Ý nghĩa đối với bài toán ảnh Fisheye

Ảnh **Fisheye** có độ cong và biến dạng cao, khiến các mô hình thông thường khó học đặc trưng chính xác.

Các cải tiến trong YOLOv11 khắc phục điều này một cách tự nhiên:

- **C2PSA Attention:** giúp mô hình “tập trung không gian” — nhận biết vùng quan trọng và bỏ qua vùng méo ít thông tin.
- **C3k2 block:** giảm số lượng tham số, giúp xử lý nhanh và ổn định hơn khi dữ liệu bị biến dạng.
- **Anchor-free Head:** tránh sai lệch bounding box do hình dạng vật thể không đều ở rìa ảnh.
- **Hiệu quả cao trên Edge Device:** thích hợp với camera Fisheye trong hệ thống nhúng (smart surveillance, autonomous drones,...).

→ Nhờ những cải tiến này, YOLOv11 tăng khả năng phát hiện đối tượng chính xác hơn trên ảnh méo, đồng thời vẫn đảm bảo hiệu năng real-time — điều kiện tiên quyết của hệ thống xử lý ảnh Fisheye.

CHƯƠNG 3: THIẾT LẬP HUẤN LUYỆN VÀ TĂNG CƯỜNG DỮ LIỆU

3.1. Chuẩn bị dữ liệu

3.1.1 Nguồn dữ liệu

Đề tài sử dụng ba bộ dữ liệu thực tế từ Kaggle để huấn luyện và đánh giá mô hình:

1. **Fisheye8k** – dữ liệu fisheye chính, gồm 5 lớp: Bus, Bike, Car, Pedestrian, Truck.
2. **VisDrone** – dữ liệu drone góc cao, tăng cường đa dạng không gian.
3. **VIPCup2020** – dữ liệu video giám sát, dùng cho gán nhãn giả và fine-tuning.

Bộ dữ liệu	Quy mô	Độ phân giải	Môi trường	Vai trò
Fisheye8k	8.000 ảnh	1280×960	Giao thông góc rộng	Tập huấn luyện chính
VisDrone	5540 ảnh	1920×1080	Drone đô thị	Bổ sung đa dạng phối cảnh
VIPCup 2020	1.000 ảnh	1280×720	Camera cố định	Dùng cho pseudo-labeling

Bảng 3.1 Bảng các bộ dữ liệu

Tất cả dữ liệu được chuẩn hóa về định dạng YOLO và resize 640×640 trước khi huấn luyện.

3.2.2. Tiền xử lý và chia dữ liệu

- **Chia dữ liệu:** Dữ liệu được chia theo tỷ lệ chuẩn: 70% cho huấn luyện (train), 15% cho kiểm thử (val), và 15% cho thử nghiệm (test).
- **Tiền xử lý cơ bản:** Bao gồm các bước:
 - Resize ảnh về kích thước đầu vào 640×640.
 - Chuẩn hóa (Normalization) giá trị pixel.
 - Kiểm tra nhãn (Check labels) để loại bỏ các lỗi định dạng.
- **Tăng cường dữ liệu (Augmentation):** Nhằm khắc phục tính chuyên biệt của tập fisheye8k và tăng tính đa dạng của dữ liệu:
 - Chuyển đổi ảnh góc nhìn thường của VisDrone sang hiệu ứng méo phồng fisheye để mô phỏng dữ liệu thực.

- Các tham số augmentation được tối ưu hóa như sau:
 - $\text{fliplr} = 0.5$: Lật ngang ngẫu nhiên 50% ảnh.
 - $\text{flipud} = 0.0$: Tắt lật dọc (do không thực tế trong ngữ cảnh giao thông).
 - $\text{degrees} = 0.0$: Không xoay ảnh để tránh méo hình không mong muốn.
 - $\text{shear} = 1.0 - 2.0$: Giảm biến dạng cắt.
 - $\text{mosaic} = 1.0$: Bật kỹ thuật ghép 4 ảnh thành 1 ở giai đoạn đầu huấn luyện.
 - $\text{close_mosaic} = 15$: Tắt Mosaic trong 15 epoch cuối để ổn định mô hình.

3.2. Thử nghiệm ban đầu và lựa chọn mô hình chính

3.2.1. Mục tiêu thử nghiệm

Giai đoạn này nhằm thiết lập mô hình cơ sở (baseline) để đánh giá hiệu năng ban đầu của các mô hình YOLO khác nhau trên dữ liệu fisheye, từ đó xác định kiến trúc phù hợp nhất cho các bước huấn luyện sâu hơn.

3.2.2. Kết quả so sánh

Thực hiện huấn luyện cơ bản trên **YOLOv8** và **YOLOv11** với cùng tập dữ liệu fisheye8k.

- **YOLOv11m** đạt **F1-score ≈ 0.32**
- **YOLOv8m** chỉ đạt **F1-score ≈ 0.24**

Kết quả này cho thấy YOLOv11 có khả năng phát hiện chính xác và cân bằng hơn giữa Precision và Recall, ngay cả trong giai đoạn baseline.

3.2.3. Phân tích kết quả

Hiệu suất vượt trội của YOLOv11 đến từ **ba cải tiến chính về kiến trúc**:

1. **Thay thế khối C2f bằng khối C3k2**: C3k2 giúp giảm số lượng tham số, đồng thời duy trì hiệu quả trích xuất đặc trưng.
2. **Bổ sung module chú ý C2PSA (Parallel Spatial Attention)**: Tăng cường khả năng tập trung của mô hình vào các vùng chứa vật thể quan trọng trong ảnh méo.

3. **Tích hợp Depthwise Convolution (DWConv):** Làm nhẹ đầu phát hiện, tăng tốc độ suy luận và giảm chi phí tính toán mà không ảnh hưởng đáng kể đến độ chính xác.

3.2.4. Kết luận lựa chọn

Từ kết quả trên, YOLOv11 được chọn làm **nền tảng chính** cho các giai đoạn cải tiến tiếp theo do đạt hiệu năng cao hơn, khả năng tổng quát tốt và kiến trúc hiện đại hơn so với YOLOv8.

3.3. Huấn luyện mở rộng với YOLOv11

Quá trình huấn luyện mở rộng tập trung vào việc **tăng cường dữ liệu** và **giảm khoảng cách miền (domain gap)** giữa ảnh fisheye và các tập dữ liệu thông thường.

- **Mở rộng dữ liệu bằng VisDrone:** Các ảnh từ VisDrone được biến đổi sang hiệu ứng méo fisheye, mở rộng tập dữ liệu từ 5.288 ảnh ban đầu lên hơn 10.828 ảnh. Việc này giúp mô hình học được các đặc trưng méo hình tương tự dữ liệu thực tế.
- **Cấu hình huấn luyện:**
 - `imgsz = 640`
 - `epochs = 50`
 - `optimizer = AdamW`
 - `cos_lr = True` (scheduler điều chỉnh tốc độ học theo đường cong cosine)

Kết quả sau giai đoạn này cho thấy mô hình học ổn định hơn, giảm lỗi bỏ sót ở các lớp nhỏ (Pedestrian, Bike) và phát hiện tốt hơn các đối tượng ở vùng méo.

3.4. Gán nhãn giả và tinh chỉnh mô hình

3.4.1. Mục tiêu

Kỹ thuật **Pseudo-labeling** được áp dụng để mở rộng dữ liệu huấn luyện mà không cần gán nhãn thủ công, giúp mô hình học được từ các nguồn dữ liệu mới (VIPcup) và tăng khả năng tổng quát hóa.

3.4.2. Quy trình thực hiện

1, Chọn model “Thầy”:

Sử dụng mô hình YOLOv11 đã được huấn luyện tốt.

2, **Chọn tập dữ liệu:** Lấy ngẫu nhiên **1.000 ảnh từ tập VIPCup** chưa có nhãn.

3, **Tạo nhãn giả:** Model “Thầy” dự đoán trên tập ảnh này, giữ lại các nhãn có độ tin cậy $\text{CONF_THRESHOLD} \geq 0.7$, lưu lại theo định dạng YOLO.

4, **Tinh chỉnh (Fine-tuning):** Gộp tập VIPCup (có nhãn giả) với dữ liệu gốc để huấn luyện lại.

- $\text{lr0} = 0.0001$
- $\text{degrees} = 0.0$, $\text{shear} = 0.0$ (giữ nguyên hình học ảnh)
- $\text{close_mosaic} = 15$ (tắt mosaic trong 15 epoch cuối)

3.4.3. Kết quả tinh chỉnh

Sau giai đoạn này, mô hình YOLOv11m đã được tiếp xúc với dữ liệu đa dạng hơn, thể hiện khả năng tổng quát hóa tốt hơn, nhận dạng chính xác trong các điều kiện ánh sáng, góc chụp và biến dạng khác nhau.

Mô hình trở nên ổn định hơn và ít bị ảnh hưởng bởi đặc thù dữ liệu góc fisheye8k.

3.5. Tổ hợp mô hình bằng Weighted Boxes Fusion (WBF)

3.5.1. Mục tiêu

Kỹ thuật **Weighted Boxes Fusion (WBF)** được áp dụng để **kết hợp ưu điểm của hai mô hình**:

1. **YOLOv8l – “Chuyên gia đặc thù”:** Được huấn luyện chủ yếu trên fisheye8k gốc, hiểu rõ phân bố dữ liệu và ánh sáng đặc trưng.
2. **YOLOv11m – “Nhà tổng quát”:** Được huấn luyện trên dữ liệu kết hợp (bao gồm nhãn giả), có khả năng khái quát hóa cao hơn.

3.5.2. Quy trình tổ hợp

1. **Dự đoán độc lập:** Cả YOLOv8l và YOLOv11m chạy dự đoán trên cùng một ảnh với Test-Time Augmentation (TTA) ($\text{augment}=\text{True}$) nhằm tăng khả năng phát hiện đối tượng khó hoặc bị che khuất.
2. **Thu thập dự đoán:** Ngưỡng tin cậy đặt thấp ($\text{conf}=0.0001$) để giữ lại tất cả các dự đoán, kể cả yếu, giúp WBF có nhiều thông tin nhất.
3. **Thực hiện WBF:** Gộp các bounding box có $\text{IoU} \geq 0.45$, tính toán lại tọa độ và độ tin cậy trung bình. Hai mô hình được gán trọng số bằng nhau.
4. **Hợp nhất kết quả:** WBF hoạt động như một “giám khảo trung lập”, chỉ giữ lại bounding box tổng hợp khi có sự đồng thuận giữa hai mô hình.

3.5.3. Kết quả tổ hợp

Kỹ thuật Ensemble (WBF + TTA) cho hiệu quả vượt trội:

- Kết quả tổng hợp ổn định hơn so với từng mô hình riêng lẻ.
- Giảm lỗi chồng hộp và tăng mAP trung bình.
- Giữ lại được nhiều vật thể khó (nhỏ, méo, nằm ở rìa ảnh).

CHƯƠNG 4: KỸ THUẬT TỔ HỢP MÔ HÌNH VỚI WEIGHTED BOXES FUSION

4.1. Mục tiêu đánh giá

Mục tiêu của chương này là đánh giá hiệu năng mô hình phát hiện đối tượng trên ảnh fisheye sau quá trình huấn luyện và tinh chỉnh. Đánh giá được thực hiện trên tập kiểm thử (test set) nhằm đo lường mức độ chính xác, khả năng khái quát hóa và độ ổn định của các mô hình trong nhiều điều kiện thực tế khác nhau.

Các mô hình được so sánh gồm:

1. **YOLOv8m** – baseline ban đầu.
2. **YOLOv11m** – mô hình cải tiến, được chọn làm nền tảng chính.
3. **YOLOv11m (fine-tuned + pseudo-label)** – mô hình đã tinh chỉnh và gán nhãn giả.
4. **YOLOv8l + YOLOv11m (WBF ensemble)** – mô hình tổ hợp bằng Weighted Boxes Fusion.

4.2. Kết quả huấn luyện và so sánh

Mô hình	F1-score
YOLOv8m (baseline)	0.24
YOLOv11m (Fisheye)	0.32
YOLOv11m (Fisheye + VisDrone)(Phase1)	0.33
YOLOv11m (Phase1 + VipCup2020 + conf)	0.45
YOLOv8l + YOLOv11m (WBF ensemble)	0.54

Bảng 4.1 Bảng kết quả huấn luyện và so sánh

Nhận xét:

- **YOLOv11m** cải thiện rõ rệt so với YOLOv8m, tăng F1-score từ 0.24 → 0.32.
- Khi áp dụng **Pseudo-labeling** và **Fine-tuning**, F1 tăng thêm, chứng tỏ dữ liệu mở rộng đã giúp mô hình khái quát tốt hơn.
- Cuối cùng, **WBF Ensemble** đạt kết quả cao nhất ở tất cả chỉ số, đặc biệt là F1-score = 0.54.

→ **WBF Ensemble** giúp tăng đồng đều hiệu năng của tất cả lớp, nhờ cơ chế hợp nhất thông tin từ hai mô hình có góc nhìn khác nhau.

4.3. Phân tích định tính

Để minh họa cho hiệu năng mô hình, các kết quả định tính (visual) cho thấy:

1. **YOLOv8m:**

Nhiều vật thể nhỏ ở vùng méo rìa bị bỏ sót, hộp bao không khớp với biên thực.

2. **YOLOv11m:**

Cải thiện đáng kể khả năng phát hiện, đặc biệt ở khu vực trung tâm ảnh.

3. **YOLOv11m (fine-tuned):** Phát hiện ổn định hơn, nhận ra nhiều vật thể bị méo hoặc ánh sáng yếu.

4. **WBF Ensemble:** Hộp bao (bounding boxes) rõ ràng, thống nhất, hạn chế chồng hộp và giảm false positive.

Kết quả thực tế cho thấy mô hình tổ hợp hoạt động hiệu quả trong cả điều kiện góc máy nghiêng, ánh sáng yếu và biến dạng fisheye nặng.

4.4. Thảo luận kết quả

Kết quả thực nghiệm cho thấy:

- Việc **thay đổi kiến trúc từ YOLOv8 sang YOLOv11** mang lại bước tiến đáng kể, đặc biệt trong bài toán có đặc thù méo hình như fisheye.
- **Tăng cường dữ liệu và gán nhãn giả** giúp mô hình học được các biến dạng khác nhau, cải thiện khả năng tổng quát hóa.
- **Weighted Boxes Fusion** chứng minh hiệu quả khi kết hợp “mô hình chuyên biệt” (YOLOv8) và “mô hình tổng quát” (YOLOv11), đạt được độ chính xác cao nhất.

Tuy nhiên, vẫn tồn tại **một số hạn chế**:

- Các đối tượng rất nhỏ ở vùng rìa ảnh vẫn bị bỏ sót do biến dạng quá lớn.
- WBF làm tăng chi phí tính toán, chưa phù hợp cho ứng dụng thời gian thực.
- Dữ liệu fisheye hiện vẫn chưa đủ phong phú về bối cảnh và điều kiện thời tiết.

CHƯƠNG 5: ĐÁNH GIÁ KẾT QUẢ VÀ THẢO LUẬN

5.1. Kết luận chung

Link code: <https://github.com/VanDung104/CompVision.git>

Đề tài đã nghiên cứu và xây dựng thành công pipeline phát hiện đối tượng trên ảnh mắt cá (fisheye) bằng cách ứng dụng các mô hình học sâu hiện đại thuộc họ YOLO (You Only Look Once). Trọng tâm của nghiên cứu là giải quyết các thách thức do biến dạng không gian và quang học trong ảnh fisheye, đồng thời đảm bảo hiệu năng cao và khả năng tổng quát hóa tốt.

Các đóng góp chính của đề tài gồm:

1. **Phân tích đặc điểm của ảnh fisheye** và đề xuất quy trình xử lý dữ liệu phù hợp, bao gồm chuyển đổi ảnh thường thành dạng méo phòng để mở rộng dữ liệu huấn luyện.
2. **Đánh giá và lựa chọn kiến trúc YOLOv11** – mô hình thế hệ mới với các cải tiến C3k2, C2PSA và DWConv, cho thấy hiệu suất vượt trội so với YOLOv8.
3. **Áp dụng kỹ thuật gán nhãn giả (Pseudo-labeling)** giúp mở rộng dữ liệu mà không cần gán nhãn thủ công, đồng thời tăng khả năng tổng quát hóa cho mô hình.
4. **Kết hợp mô hình bằng Weighted Boxes Fusion (WBF)** để tận dụng ưu điểm của hai hướng huấn luyện: mô hình chuyên biệt (YOLOv8) và mô hình tổng quát (YOLOv11).
5. **Tối ưu hóa pipeline huấn luyện** với các chiến lược tăng cường dữ liệu (augmentation), chia tập thông minh (day/night), và tinh chỉnh siêu tham số.

Kết quả cuối cùng cho thấy mô hình tổ hợp **YOLOv8l + YOLOv11m (WBF)** đạt: $F1\text{-score} = 0.54$

Cao nhất trong toàn bộ thí nghiệm, đồng thời thể hiện khả năng phát hiện ổn định trên nhiều góc nhìn và điều kiện ánh sáng khác nhau.

Điều này chứng minh pipeline được đề xuất là hướng tiếp cận hiệu quả cho các bài toán thị giác máy tính trên dữ liệu bị méo hình học, như giám sát giao thông, quan sát góc rộng, hoặc thị giác robot.

5.2. Hạn chế của nghiên cứu

Mặc dù đạt được kết quả khả quan, đề tài vẫn tồn tại một số hạn chế:

- **Giới hạn dữ liệu:**
Các tập fisheye hiện có kích thước nhỏ (khoảng 8.000 ảnh), chưa đủ bao quát mọi bối cảnh giao thông, thời tiết và môi trường khác nhau.
- **Hiệu năng thời gian thực:**
WBF làm tăng thời gian suy luận do cần xử lý đồng thời hai mô hình. Việc triển khai thực tế trên thiết bị nhúng (edge devices) cần tối ưu thêm.
- **Phát hiện vật thể nhỏ ở vùng rìa ảnh:**
Dù đã cải thiện nhờ YOLOv11, nhưng các đối tượng rất nhỏ hoặc bị méo mạnh vẫn còn bị bỏ sót.
- **Chưa đánh giá trên video liên tục:**
Toàn bộ thí nghiệm được thực hiện trên ảnh tĩnh, chưa xem xét tính ổn định giữa các khung hình trong chuỗi video.

5.3. Hướng phát triển tương lai

Để nâng cao hiệu năng và mở rộng ứng dụng, một số hướng nghiên cứu có thể được thực hiện trong tương lai:

1. **Tăng kích thước và độ đa dạng của dữ liệu fisheye:** Kết hợp thêm dữ liệu từ các hệ thống camera góc rộng, xe tự hành hoặc UAV để cải thiện khả năng tổng quát hóa.
2. **Triển khai trên thiết bị biên (Edge AI):** Áp dụng kỹ thuật lượng tử hóa (quantization) và tỉa mô hình (pruning) để tối ưu mô hình cho tốc độ suy luận cao hơn trên thiết bị hạn chế tài nguyên.
3. **Huấn luyện kết hợp video – Temporal Learning:** Kết hợp thông tin giữa các khung hình liên tiếp (temporal consistency) nhằm ổn định dự đoán và giảm hiện tượng nhấp nháy (flicker).
4. **Nghiên cứu các kiến trúc mới hơn như YOLOv12 hoặc RT-DETR:** Đánh giá khả năng thay thế YOLOv11 bằng các mô hình detection-transformer thế hệ mới có khả năng học không gian phi tuyến mạnh hơn.
5. **Ứng dụng thực tế:** Tích hợp mô hình vào hệ thống giám sát giao thông thông minh (ITS) hoặc robot thị giác, nơi yêu cầu góc nhìn rộng và khả năng phát hiện trong môi trường phức tạp.

5.4. Kết luận cuối cùng

Qua toàn bộ quá trình nghiên cứu, đề tài đã chứng minh rằng việc kết hợp YOLOv11, kỹ thuật gán nhãn giả, và tổ hợp mô hình WBF là giải pháp hiệu quả để nâng cao khả năng phát hiện đối tượng trong ảnh fisheye – một dạng dữ liệu có nhiều thách thức về hình học.

Kết quả đạt được không chỉ khẳng định tính khả thi và hiệu quả của pipeline được đề xuất, mà còn mở ra hướng nghiên cứu sâu hơn trong thị giác máy tính ứng dụng thực tế, đặc biệt trong các hệ thống quan sát góc rộng và xe tự hành trong tương lai.

Tài Liệu Tham Khảo

- [1] Slide bài giảng do thầy TS. Vũ Huân cung cấp.
- [2] https://openaccess.thecvf.com/content/CVPR2024W/AICity/papers/Duong_Robust_Data_Augmentation_and_Ensemble_Method_for_Object_Detection_in_CVPRW_2024_paper.pdf
- [3] **Muhammad Yaseen** (2024). What is YOLOv8: An In-Depth Exploration of The Internal Features of The Next Generation Object Detector.
- [4] **Rahima Khanam and Muhammad Hussain** (2024). YOLOv11: An Overview of The Key Architectural Enhancements.
- [5] **Priyanto Hidayatullah, Nurjannah Syakranib, Muhammad Rizqi Sholahuddinc, Trisna Gelard, Refdinal Tubaguse** (2025). YOLOv8 to YOLO11: A Comprehensive Architecture In-depth Comparative Review